


PDF 版面文本块提取 合成原型证据

用于验证逐页块、标题/正文/图片归组、bbox 与 map-area 坐标、JSON/API 契约、质量指标和未解决问题日志。该证据只证明本合成 born-digital PDF 的能力边界，不冒充客户案例。


页面	文本/图片块	文章组	bbox 平均 IoU	待复核
3	28	4	0.9711	1



图中彩色框直接使用 API 响应里的 144 dpi map-area 坐标绘制。

1. 逐页版面块与跨页文章归组

第 1 页包含跨栏标题、图片、图注、正文和引语；第 2 页同时包含上一篇文章的 continuation 区域和一篇新文章。article-001 因可见标题词与 CONTINUED 标记跨页连接，article-002 保持独立。



框标签依次显示阅读顺序、块类型与 article_id。

2. 图片归属不确定时不强行猜测

第 3 页有两篇独立文章。居中的 Figure 3 图片跨过两栏中线，其图注也与该图片相邻。原型将两者 article_id 保持为 null，并生成 AMBIGUOUS_ARTICLE_ASSOCIATION 待复核项。



问题	AMBIGUOUS_ARTICLE_ASSOCIATION
状态	open
候选文章	article-003, article-004
处置	由复核者选择文章，或明确标记为跨文章共享图片。

3. bbox、map-area 与 JSON/API 契约

同一块同时返回顶点为左上角的 PDF 点坐标、PDF 原生左下角坐标，以及按 2 倍比例渲染后的整数像素 map-area。这样网页预览和审计工具无需隐式换算。

字段	原点	单位	用途
bbox	左上角	pt	页面版面与模型审计
bbox_pdf	左下角	pt	PDF 原生坐标互操作
map_area.coords	左上角	px	144 dpi 页面图片的 HTML rect

样例响应块

```
{
  "article_id": "article-001",
  "bbox": {
    "origin": "top-left",
    "unit": "pt",
    "x0": 42.0,
    "x1": 343.368,
    "y0": 54.858,
    "y1": 78.858
  },
  "id": "p1-t01",
  "map_area": {
    "canvas_height": 1684,
    "canvas_width": 1191,
    "coords": [
      84,
      110,
      687,
      158
    ],
    "origin": "top-left",
    "render_scale": 2.0,
    "shape": "rect",
    "unit": "px"
  },
  "reading_order": 1,
  "type": "title"
}
```

Endpoint	POST /v1/layout/extract
Schema	OpenAPI 3.1 / openapi.yaml
成功响应	document + pages[].blocks + articles + issues
坐标画布	页面点尺寸 x 2，输出整数像素

4. 自动化指标、验证和未证明范围

指标	结果	阈值
块 precision / recall	1.0000 / 1.0000	≥ 0.98
块类型准确率	1.0000	≥ 0.98
文章归组准确率	1.0000	≥ 0.98
阅读顺序成对准确率	1.0000	≥ 0.95
bbox 平均 IoU	0.9711	≥ 0.90
最大边缘误差	0.792 pt	记录值
JSON/map-area 契约	通过	必须通过

已验证范围

- 完全合成的 3 页 born-digital PDF，包含双栏、跨页延续、图片、图注和引语。
- 逐页块检测、块类型、article_id、阅读顺序、bbox/map-area 换算和开放问题输出。
- 源文件、响应 JSON、审计报告和视觉框选证据均可用 SHA-256 复查。

未证明范围

- 扫描件 OCR、手写内容、复杂表格、任意未知版式和生产级吞吐。
- 客户真实 PDF 上的最终准确率、托管 API、认证、监控或 SLA。
- 唯一待复核项必须由人工选择文章，或明确标记为共享图片。

冻结指纹

Source PDF SHA-256: 6afcf81603b7979c4fd4695cf6ba72ad18e48f46b37effc7f0beb74e3cf598d7

Sample response SHA-256: 492bfc6e74098f2692ae5f740568c5c5dbade6813f74d8754630885e1e3be0b2

Audit report SHA-256: 6bd44fd5e75d76f1354b5c34a86c5d5ae5c885bddd669b52658fa9669acd810